Lab7　k-Means 应用实践

实验简介：利用 Python 实现 k-Means 聚类。使用 Python 访问 Baidu Web 的 API，先用 Baidu Web 的 API 获得数据，然后用 kMeans 算法对地理位置进行聚类，并对聚类得到的簇进行后处理。代码文件：kmeans.py。

作业要求：作业要求：见 QQ 群文件："作业要求.pdf"

1、获取地图数据

百度地图提供 API 的网址：

http://lbsyun.baidu.com/index.php?title=webapi/guide/webservice-placeapi

（1）注册成为开发者

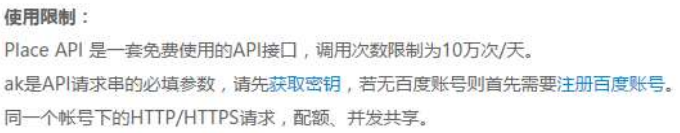

注册登录百度账号之后，点击获取秘钥，弹出注册成为开发者页面：

点击创建应用：

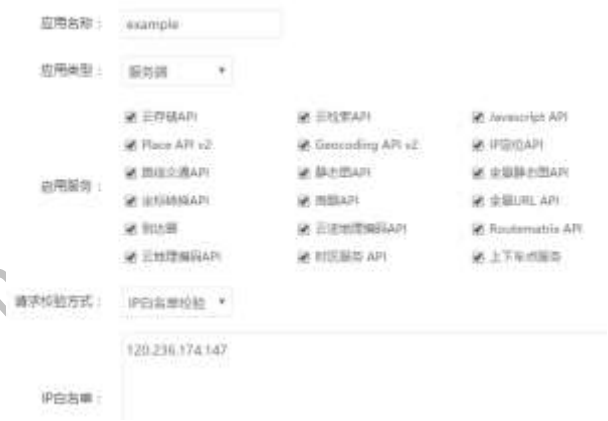

注意：IP 白名单中要填入访问方的公网 IP，查看 IP 白名单中的 IP 是否与本机 IP 一致，若不一致则改成本机 IP，这里是中大公网 IP。为了获取 IP，打开 http://txt.go.sohu.com/ip/soip 以检查本机实际访问公网的 IP。

应用类型选择服务端，可以看到下面有需要的 Place API v2 服务。点击确定就可以看到秘钥，如下（AK 部分）：

（2）使用 API 获取数据（api.py）

查看网页，了解 API 的使用格式：

http://api.map.baidu.com/place/v2/search?q=查询内容&page_size=范围记录数量&page_num=分页页码&region=地区&output=数据格式&ak=秘钥

打开命令窗口，并切换至文件“api.py”所在目录，运行：

> python api.py

观察获得的数据和目录下的 Restaurant_Data_Beijing.txt 文件中保存的数据是一致：

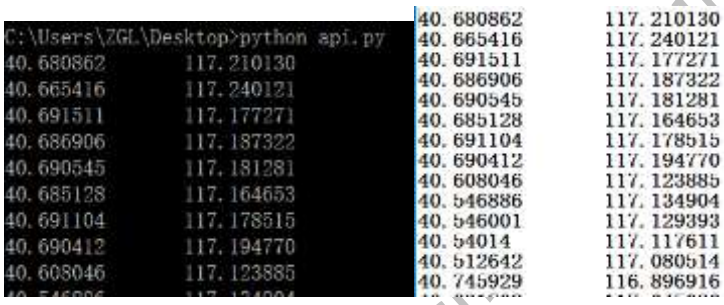

2、实现 kMean 聚类

（1）建立辅助函数

函数 loadDataSet()读取文件的数据，函数 distEclud()计算两个向量的欧式距离，函数 randCent()随机生成 k 个随机质心。

>>> import kmeans

从文本文件中构建矩阵：

>>> dataset = mat(kmeans.loadDataSet(‘testSet.txt’))

测试函数 randCent()：

>>> min(dataset[:, 0])

>>> min(dataset[:, 1])

>>> max(dataset[:, 1])

>>> max(dataset[:, 0])

查看 randCent()能否生成 min 到 max 之间的值：

>>> kmeans.randCent(dataset, 2)

```
# 测试距离计算函数：
>>> kmeans.distEclud(dataset[0], dataset[1])
```

（2）kMean 算法实现

函数 kMeans()接受 4 个输入参数，数据集及簇的数目是必选参数，而计算距离和创建初始质心的函数可选。

```
>>> dataset = mat(kmeans.loadDataSet('testSet.txt'))
# 查看聚类结果：
>>> myCentroids, clustAssing = kmeans.kMeans(dataset, 4)
# 参看迭代的次数及结果：
>>> myCentroids
>>> clustAssing
```

3、利用 kMeans 对地图上的点聚类

餐厅是一个城市的重要组成部分，在北京城内有不少餐厅，当今地政府想要建立 4 个餐厅管理服务点，对整个北京中的餐厅进行管理，但是无法确定管理服务点要建在哪里才比较合理？假设现在给出北京地区的一些饭店所在的经纬度，具体分布如下图所示。尝试利用 **kMeans** 依据饭店的分布，找其各部分的中心位置。

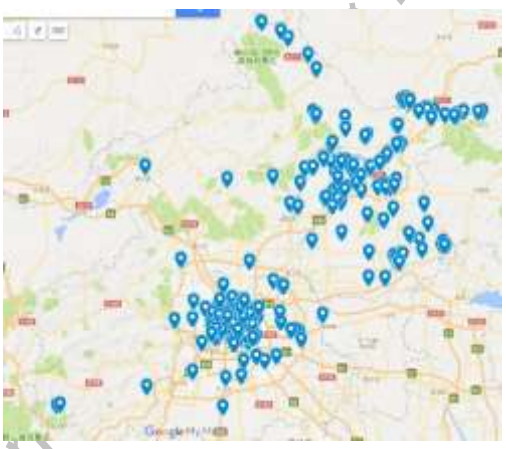

（1）准备数据

饭店的经纬度数据存放在 Restaurant_Data_Beijing.txt 文件中，其中每一行数据的第一列代表地点的纬度（北纬），第二列代表经度（东经）：

```
>>> dataMat = kmeans.loadDataSet('Restaurant_Data_Beijing.txt')
>>> dataMat
```

（2）对地理坐标进行聚类

函数 distSLC()返回地球表面两点之间的距离，函数 clusterPlaces ()将文本文件中的地点进行聚类并画出结果。

```
>>> kmeans.clusterPlaces(3)
```

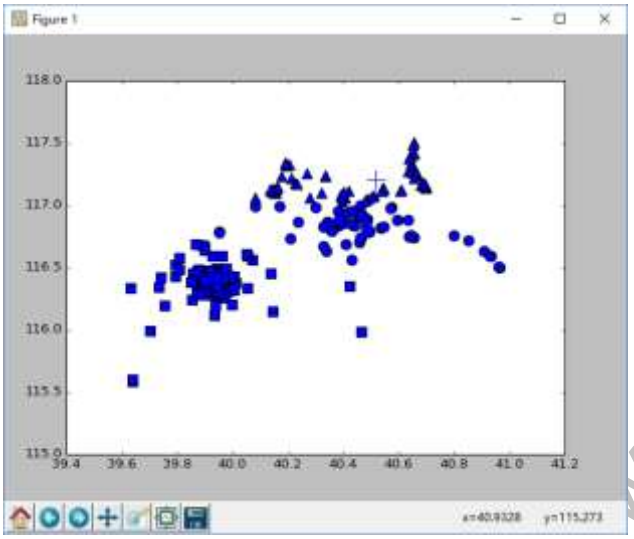

可与 google map 中的标记进行对比。

不同簇的数据点用不同的形状标记，+号所标注的就是对应簇的质心。可看到地点被大致分成 3 部分。依次修改 k 值为 4、5、6，观察相应的图像输出：

```
>>> kmeans.clusterPlaces(4)
>>> kmeans.clusterPlaces(5)
>>> kmeans.clusterPlaces(6)
```

4、操作习题

（1）利用 sklearn.cluster.kMeans 聚类该数据集，并访问一些重要属性和方法，用轮廓系数评估不同 k 值的聚类效果，选择最佳 k 值。

（2）利用 sklearn.mixture.GaussianMixture 聚类该数据集，并访问一些重要属性和方法，测试不同的参数 covariance_type 值的效果。

（3）实现 PPT 中的示例 1、示例 2