

# 第6讲 k-近邻算法

---

- **kNN算法**
- **sklearn.neighbors**
- **数据预处理**

Fundamentals of Machine Learning\_WANGBIANQIN

# kNN 算法

□ **相似度**：向量间距离度量(Distance Measure)的一种常用方式

两个向量的距离函数 $\text{dist}(x_i, x_j)$ 需要满足一些基本性质

非负性(Positivity Separation):  $\text{dist}(x_i, x_j) \geq 0$

同一性(Constancy of Self-Similarity) :  $\text{dist}(x_i, x_j) = 0$ , iff  $x_i = x_j$

对称性(Symmetry):  $\text{dist}(x_i, x_j) = \text{dist}(x_j, x_i)$

三角不等式(triangular inequality):  $\text{dist}(x_i, x_j) \leq \text{dist}(x_i, x_k) \leq \text{dist}(x_k, x_j)$

# kNN 算法

## □ 向量 $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})$ 与 $\mathbf{x}_j = (x_{j1}, x_{j2}, \dots, x_{jd})$ 之间距离

- 欧氏距离(Euclidean Distance) :

$$\text{dist}(x_i, x_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{k=1}^d |x_{ik} - x_{jk}|^2}$$

- 曼哈顿距离(Manhattan Distance) :

$$\text{dist}(x_i, x_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{k=1}^d |x_{ik} - x_{jk}|$$

# kNN 算法

□ 向量  $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})$  与  $\mathbf{x}_j = (x_{j1}, x_{j2}, \dots, x_{jd})$  之间距离

- 闵可夫斯基距离(Minkowski Distance) :

$$dist(x_i, x_j) = \sqrt[r]{\sum_{k=1}^d |x_{ik} - x_{jk}|^r}$$

- 切比雪夫距离(Chebyshev Distance) :  $r = \infty$

$$dist(x_i, x_j) = \max |x_{ik} - x_{jk}|$$

# kNN 算法

---

## ◆ 示例：计算欧氏距离

```
import numpy as np

vector1 = np.array([1, 2, 3])
vector2 = np.array([4, 5, 6])

op1 = np.sqrt(np.sum(np.square(vector1-vector2)))
op2 = np.linalg.norm(vector1-vector2)

print(op1)
print(op2)
```

```
5.196152422706632
5.196152422706632
```

# kNN 算法

## ◆ 示例：计算曼哈顿距离

```
import numpy as np

vector1 = np.array([1, 2, 3])
vector2 = np.array([4, 5, 6])

op3 = np.sum(np.abs(vector1-vector2))
op4 = np.linalg.norm(vector1-vector2, ord=1)

print(op3)
print(op4)
```

```
9
9.0
```

# kNN 算法

---

## ◆ 示例：切比雪夫距离(Chebyshev Distance)

```
import numpy as np

vector1 = np.array([1, 2, 3])
vector2 = np.array([4, 7, 6])

op5 = np.abs(vector1-vector2).max()
op6 = np.linalg.norm(vector1-vector2, ord=np.inf)

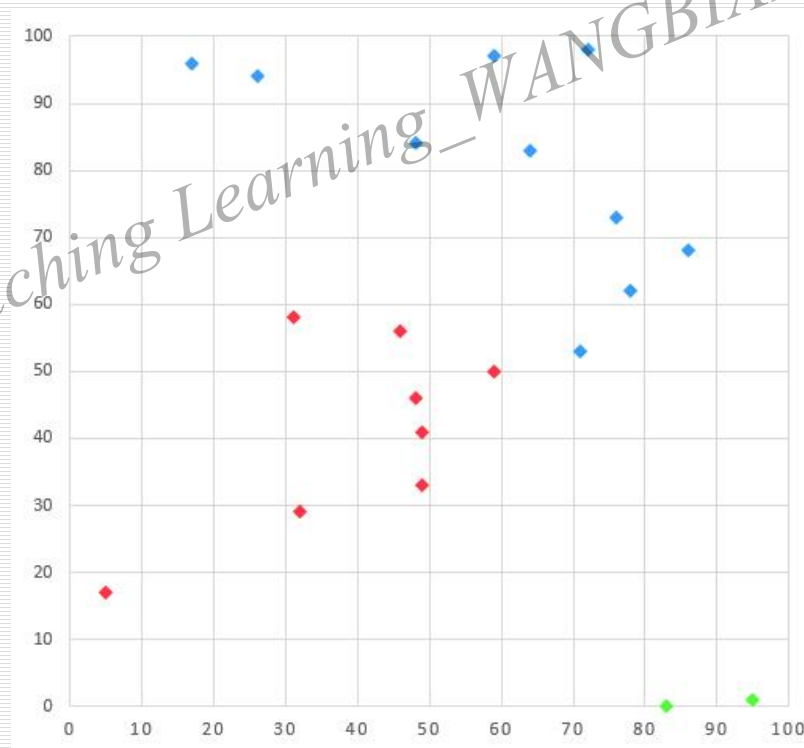
print(op5)
print(op6)
```

```
5
5.0
```

# kNN 算法

◆ 示例1：已知20个数据样本，其分类结果如下图(三个类别)

x1	x2	y
49	33	A
46	56	A
64	83	B
76	73	B
59	50	A
72	98	B
48	84	B
49	41	A
78	62	B
48	46	A
83	0	C
59	97	B
71	53	B
26	94	B
86	68	B
17	96	B
95	1	C
31	58	A
32	29	A
5	17	A

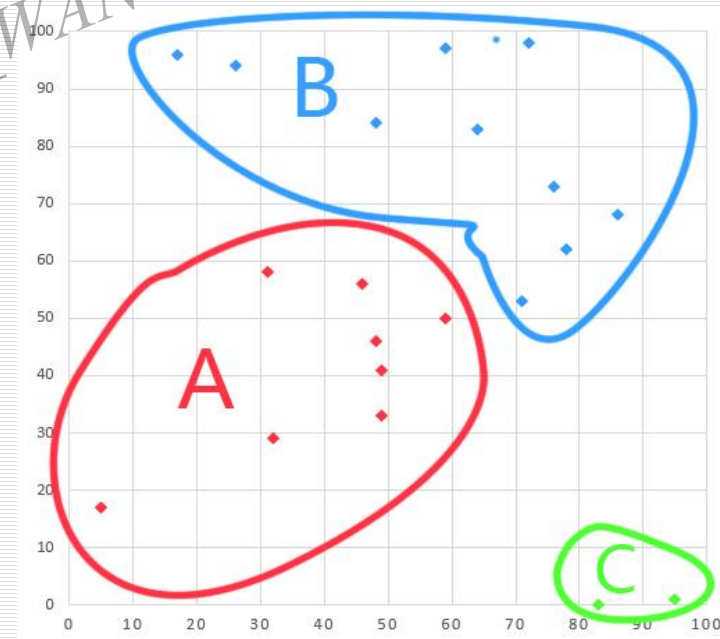




# kNN算法

## ◆ 示例1：已知20个数据样本，其分类结果如下图(三个类别)

- 样本数据集分为A、B、C三个类别
- 问题：通过20个已知类别的样本，对一个新数据（ $x=60, y=64$ ）进行分类



# kNN算法

## ◆ 示例1：已知20个数据样本，其分类结果如下图(三个类别)

- 先计算新数据与各样本数据间距离
- 按距离递增次序排序
- 选取与当前点距离最小的 $k$ 个点， $k = 7$
- 确定前 $k$ 个点所属类别的出现概率


x1	x2	y	x1	x2	y	距离
49	33	A	49	33	A	14.03567
46	56	A	46	56	A	15.55635
64	83	B	64	83	B	16.12452
76	73	B	76	73	B	18.11077
59	50	A	59	50	A	18.35756
72	98	B	72	98	B	19.41649
48	84	B	48	84	B	21.63331
49	41	A	49	41	A	23.32381
78	62	B	78	62	B	25.4951
48	46	A	48	46	A	26.30589
83	0	C	83	0	C	29.61419
59	97	B	59	97	B	32.89377
71	53	B	71	53	B	33.01515
26	94	B	26	94	B	36.05551
86	68	B	86	68	B	44.82187
17	96	B	17	96	B	45.34314
95	1	C	95	1	C	53.60037
31	58	A	31	58	A	68.00735
32	29	A	32	29	A	72.06941
5	17	A	5	17	A	72.34639

# kNN算法

## ◆ 示例1：已知20个数据样本，其分类结果如下图(三个类别)

- 7个点中有4个属于B类，3个属于A类， $P(A) = 3 / 20$ ,  $P(B) = 4 / 20$
- 返回前k个点出现概率最高的类别作为当前点的预测类别

由此将新数据归为？类



# kNN算法

---

## □ KNN思想

- 当一个未知标签的数据需要分类时，
- 求其与训练集中每个数据对象的距离，
- 然后选择离未知数据最近的 $k$ 个点，
- 分别查看其归属，
- 最后将未知数据归入包含点数最多的类别。

# kNN算法

---

输入：训练样本， $k$ 为近邻数，未知数据点 $x$

输出： $x$ 所属的类别

处理：

- (1) 计算当前数据点与已知类别数据集中的每个点之间的距离；
- (2) 按照距离递增次序排序；
- (3) 选取与当前点距离最小的 $k$ 个点；
- (4) 确定前 $k$ 个点所属类别的出现概率；
- (5) 返回前 $k$ 个点出现概率最高的类别作为当前点的预测类别。

# kNN算法

---


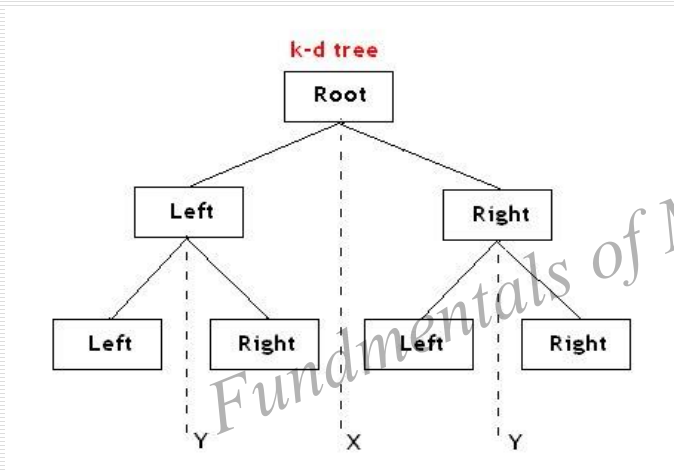
## □ $k$ NN算法性能

- 最简单有效的分类方法
- 无需估计参数，即无需训练，属非参数模型
- 只计算“最近”邻居样本。当样本不平衡时， $k$ 个邻居中大容量类的样本占多数或占极少数。
- 计算复杂度高，需计算新的数据点与样本集中每个数据的距离，时间复杂度是 $O(n)$ ，空间复杂度也高。

# kNN算法

## □ kNN实现：kd 树

◆ 示例：给定一个二维空间的数据集： $T=\{(2,3), (5,4), (9,6), (4,7), (8,1), (7,2)\}$ 构建一个平衡kd树



- 构造 kd 树，搜索 kd 树

李航著. 统计学习方法（第2版）. 北京：清华大学出版社，2019.5

# sklearn.neighbors

---

□ **class** : sklearn.neighbors.KNeighborsClassifier(n\_neighbors=5, \*, weights='uniform', algorithm='auto', leaf\_size=30, p=2, metric='minkowski', metric\_params=None, n\_jobs=None, \*\*kwargs)

<https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html#sklearn.neighbors.KNeighborsClassifier>



# sklearn.neighbors

## □ Methods

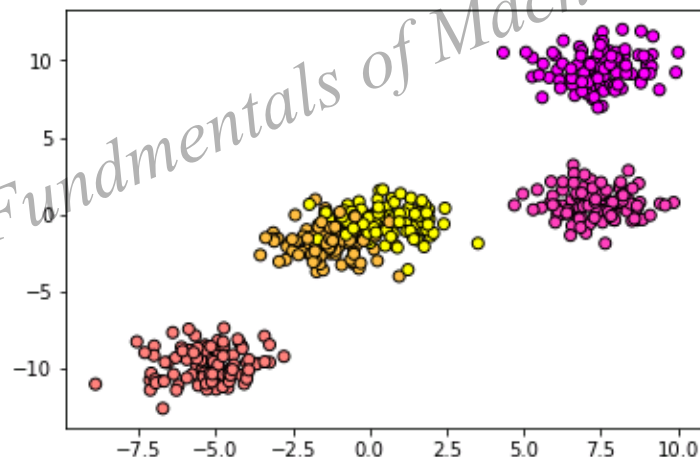
<code><a href="#">fit</a>(self, X, y)</code>	Fit the model using X as training data and y as target values
<code><a href="#">get_params</a>(self[, deep])</code>	Get parameters for this estimator.
<code><a href="#">kneighbors</a>(self[, X, n_neighbors, ...])</code>	Finds the k-neighbors of a point.
<code><a href="#">kneighbors_graph</a>(self[, X, n_neighbors, mode])</code>	Computes the (weighted) graph of k-Neighbors for points in X
<code><a href="#">predict</a>(self, X)</code>	Predict the class labels for the provided data.
<code><a href="#">predict_proba</a>(self, X)</code>	Return probability estimates for the test data X.
<code><a href="#">score</a>(self, X, y[, sample_weight])</code>	Return the mean accuracy on the given test data and labels.
<code><a href="#">set_params</a>(self, **params)</code>	Set the parameters of this estimator.

# sklearn.neighbors

## ◆ 示例：sklearn.neighbors.KNeighborsClassifier

```
# 生成样本数为500, 类别数为5的数据集  
data2 = make_blobs(n_samples=500, centers=5, random_state=8)  
X2, y2 = data2  
# 用散点图将数据集进行可视化  
plt.scatter(X2[:,0], X2[:,1], c=y2, cmap=plt.cm.spring, edgecolor='k')
```

<matplotlib.collections.PathCollection at 0x9645208>



# sklearn.neighbors

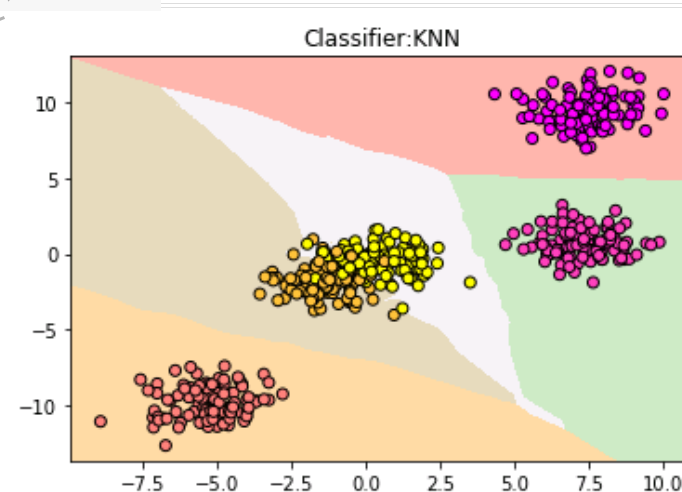
## ◆ 示例：sklearn.neighbors.KNeighborsClassifier

```
clf = KNeighborsClassifier()
clf.fit(X2,y2)

# 画出决策边界
x_min, x_max = X2[:, 0].min() - 1, X2[:, 0].max() + 1
y_min, y_max = X2[:, 1].min() - 1, X2[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, .02),
                     np.arange(y_min, y_max, .02))

Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
Z = Z.reshape(xx.shape)

plt.pcolormesh(xx, yy, Z, cmap=plt.cm.Pastel1)
plt.scatter(X2[:, 0], X2[:, 1], c=y2, cmap=plt.cm.spring, edgeco
plt.xlim(xx.min(), xx.max())
plt.ylim(yy.min(), yy.max())
plt.title("Classifier:KNN")
#plt.scatter(6.75, 4.82, marker='*', c='red', s=200)
```



```
print('模型正确率: {:.2f}'.format(clf.score(X2,y2)))
```

模型正确率: 0.96

# sklearn.neighbors

---

- ❑ **sklearn.neighbors.KNeighborsClassifier** : 适合多类别分类
- ❑ **sklearn.neighbors.KNeighborsRegressor** : 回归预测

Fundamentals of Machine Learning - WANG BIANQIN

# sklearn.neighbors

---

- ❑ **class** : sklearn.neighbors.KNeighborsRegressor(n\_neighbors=5, \*, weights='uniform', algorithm='auto', leaf\_size=30, p=2, metric='minkowski', metric\_params=None, n\_jobs=None, \*\*kwargs)

<https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsRegressor.html#sklearn.neighbors.KNeighborsRegressor>

# sklearn.neighbors

---

## □ Methods

[`fit`](#)(self, X, y)

Fit the model using X as training data and y as target values

[`get\_params`](#)(self[, deep])

Get parameters for this estimator.

[`kneighbors`](#)(self[, X, n\_neighbors, ...])

Finds the K-neighbors of a point.

[`kneighbors\_graph`](#)(self[, X, n\_neighbors, mode])

Computes the (weighted) graph of k-Neighbors for points in X

[`predict`](#)(self, X)

Predict the target for the provided data

[`score`](#)(self, X, y[, sample\_weight])

Return the coefficient of determination  $R^2$  of the prediction.

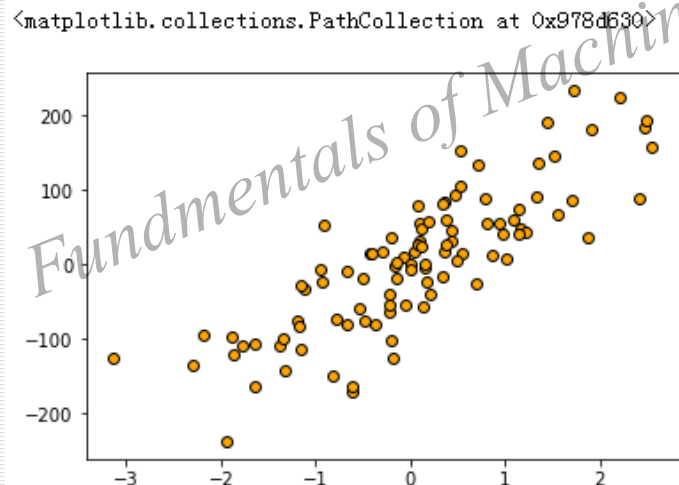
[`set\_params`](#)(self, `*params`)

Set the parameters of this estimator.


# sklearn.neighbors

## ◆ 示例：sklearn.neighbors.KNeighborsRegressor

```
# 导入make_regression数据生成器
from sklearn.datasets import make_regression
# 生成特征数量为1, 噪声为50数据集
X, y = make_regression(n_features=1, n_informative=1, noise=50, random_state=8)
# 用散点图将数据集进行可视化
plt.scatter(X, y, c='orange', edgecolor='k')
```



```
# 导入KNN回归模型
from sklearn.neighbors import KNeighborsRegressor
reg = KNeighborsRegressor()
# KNN模型拟合数据
reg.fit(X, y)
# 预测结果可视化
z = np.linspace(-3, 3, 200).reshape(-1, 1)
plt.scatter(X, y, c='orange', edgecolor='k')
plt.plot(z, reg.predict(z), c='k', linewidth=3)
# 添加标题
plt.title('KNN Regressor')
```



```
print('模型评分: {:.2f}'.format(reg.score(X, y)))
```

模型评分: 0.77

# 数据预处理





# 数据预处理

---

- 特征工程(Feature Engineering)：指对于特定应用，如何找到最佳数据表示。

“数据决定了机器学习的上限，而算法只是尽可能逼近这个上限而已”

- 特征处理：数据预处理
- 特征选择：从特征集中选择特征子集
- 特征降维：减少特征数量，并保留大部分有效信息

# 数据预处理

## □ sklearn中的数据预处理和特征工程

### Classification

Identifying to which category an object belongs to.

**Applications:** Spam detection, Image recognition.

**Algorithms:** SVM, nearest neighbors, random forest, ... — Examples

### Regression

Predicting a continuous-valued attribute associated with an object.

**Applications:** Drug response, Stock prices.

**Algorithms:** SVR, ridge regression, Lasso, ... — Examples

### Clustering

Automatic grouping of similar objects into sets.

**Applications:** Customer segmentation, Grouping experiment outcomes

**Algorithms:** k-Means, spectral clustering, mean-shift, ... — Examples

### Dimensionality reduction

Reducing the number of random variables to consider.

**Applications:** Visualization, Increased efficiency

**Algorithms:** PCA, feature selection, non-negative matrix factorization. — Examples

### Model selection

Comparing, validating and choosing parameters and models.

**Goal:** Improved accuracy via parameter tuning

**Modules:** grid search, cross validation, metrics. — Examples

### Preprocessing

Feature extraction and normalization.

**Application:** Transforming input data such as text for use with machine learning algorithms.

**Modules:** preprocessing, feature extraction. — Examples

# 数据预处理

---

## □ sklearn中的数据预处理和特征工程

- sklearn.preprocessing : 几乎包含数据预处理的所有内容
- sklearn.Impute : 填补缺失值专用
- sklearn.feature\_selection : 包含特征选择的各种方法的实践
- sklearn.decomposition : 包含降维算法

# 数据预处理

---

## □ sklearn.preprocessing

<https://scikit-learn.org/stable/modules/classes.html#module-sklearn.preprocessing>

- 范围缩放 ( Feature scaling ) : 将特征的取值区间缩放到某个特定范围, 如最大最小缩放 ( min max scaling )
- 标准化 ( standardization ) : 均值为零, 标准差为1
- 归一化 ( normalization ) : 把每个特征值都归到0-1范围
- 二值化 ( binarization ) : 将数值特征向量转换为布尔型向量
- 独热编码 : 特征向量的每个特征与特征的非重复总数相对应, 通过one-of-k的形式对每个值进行编码
- 标签编码 : 将标签编码转换成数字形式

# 数据预处理

---

- 不同特征常具有不同单位或量纲：

数量级的差异将导致量级较大的特征占主导

数量级的差异将导致迭代收敛速度减慢

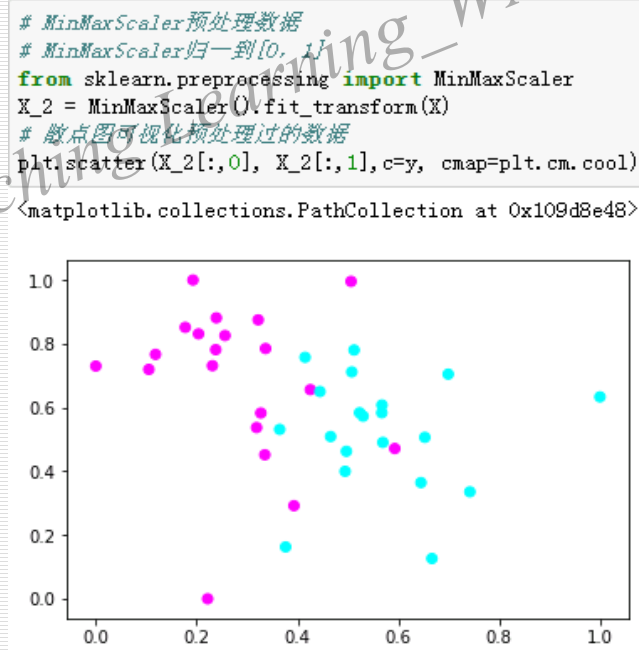

有些距离算法对于数据的数量级非常敏感

- 无量纲化：将不同规格的数据转换到同一规格，  
或不同分布的数据转换到某个特定分布的需求

# 数据预处理

- ◆ 示例：class sklearn.preprocessing.StandardScaler(\*,  
copy=True, with\_mean=True, with\_std=True)

$$x_{new} = \frac{x - \min}{\max - \min}$$




# 数据预处理

◆ 示例：class sklearn.preprocessing.StandardScaler(\*,  
copy=True, with\_mean=True, with\_std=True)

$$x_{new} = \frac{x - \mu}{\sigma}$$


```
# 导入numpy库
import numpy as np
# 导入可视化库
import matplotlib.pyplot as plt
# 浏览器中显示图
%matplotlib inline
# 导入数据集生成工具
from sklearn.datasets import make_blobs
# 生成40个样本点，分成两类
X, y = make_blobs(n_samples=40, centers=2, random_state=50, cluster_std=2)
# 散点图可视化数据
plt.scatter(X[:,0], X[:,1], c=y, cmap=plt.cm.cool)
```

<matplotlib.collections.PathCollection at 0x10918630>



```
# StandardScaler预处理数据
# StandardScaler将所有数据的特征值转换为均值为0，方差为1
from sklearn.preprocessing import StandardScaler
X_1 = StandardScaler().fit_transform(X)
# 散点图可视化预处理过的数据
plt.scatter(X_1[:,0], X_1[:,1], c=y, cmap=plt.cm.cool)
```

<matplotlib.collections.PathCollection at 0x11a15780>



# 数据预处理

---

- ◆ 示例：class sklearn.preprocessing.normalize(X,  
norm='l2', \*, axis=1, copy=True, return\_norm=False)

```
from sklearn.preprocessing import Normalizer  
X = [[4, 1, 2, 2], [1, 3, 9, 3], [5, 7, 5, 1]]  
transformer = Normalizer().fit_transform(X)  
transformer
```

```
array([[0.8, 0.2, 0.4, 0.4],  
       [0.1, 0.3, 0.9, 0.3],  
       [0.5, 0.7, 0.5, 0.1]])
```



# kNN 算法

---

□ 向量的范数(norm)：表示向量的长度或大小

向量  $\mathbf{x} = (x_1, x_2, \dots, x_d)$  的范数计算

一范数：  $l_1 = |x_1| + |x_2| + \dots + |x_d|$

二范数：  $l_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_d^2}$

无穷范数：  $l_\infty = \max(|x_k|), k = 1, 2, \dots, d$